Yasmina FARID

Stage Data Scientist – stage de fin d'études de 6 mois à partir de 02/2027

M2 Informatique, parcours CODIA – Connaissances, science des données et intelligence artificielle – Université de Strasbourg

Strasbourg, France | Email : yasmina.dsml@gmail.com

PROFIL

Étudiante en M2 data science et IA. Je construis des jeux de données réels multi-sources, puis développe, entraîne et compare des modèles de machine learning et de deep learning en Python (PyTorch, TensorFlow, Keras), dont des modèles séquentiels (RNN, LSTM) et des séries temporelles d'images satellites. J'ai aussi travaillé sur des données tabulaires, géographiques, textuelles, génomiques et sur des documents PDF.

FORMATION

Master Informatique, parcours CODIA – Connaissances, science des données et IA | Université de Strasbourg | 09/2025 – 08/2027

- M2 (en cours) : données à large échelle, entreposage de données massives distribuées, Edge AI, mise en œuvre de l'IA.
- M1 : science des données et apprentissage, statistiques pour la science des données, apprentissage profond (deep learning), données complexes, programmation parallèle.

Licence Informatique | Université de Strasbourg | 09/2020 – 06/2024

- Programmation C et Java, bases de données (SQL, PL/SQL, Oracle), réseaux, génie logiciel, Git, développement web et d'applications.

PROJETS DATA SCIENCE

Modèles séquentiels : régression logistique, RNN et LSTM | Projet de M1, équipe de 3 | Python, TensorFlow, Keras, Hugging Face

- Comparaison de trois modèles de classification de texte (régression logistique de référence, RNN, LSTM avec embeddings GloVe), développés par mes soins ; augmentation des données par back-traduction (Hugging Face Transformers).
- Validation croisée stratifiée à 5 folds puis test indépendant ; détection d'une fuite d'information qui surestimait les scores.
- Accuracy de 0,59 sur le test indépendant pour les trois modèles ; fuite localisée au découpage des folds et corrigée par validation croisée groupée : la régression logistique passe de 0,73 à 0,64 et le LSTM devient le meilleur modèle (0,69).

Classification de cultures agricoles à partir de séries temporelles d'images satellites (Sentinel-2) | Projet de M1, équipe de 3, contribution individuelle | Python, scikit-learn, imbalanced-learn

- Ingénierie de caractéristiques sur séries temporelles mensuelles : statistiques par canal et par mois, indice de végétation NDVI (cycle de croissance).
- Pipeline scikit-learn (standardisation, sélection de variables, régression logistique, 20 classes déséquilibrées) optimisé par GridSearchCV.
- F1 macro de 0,48 sur le test (hasard : 0,05) et de 0,61 en validation croisée.

TER : superposition des caractéristiques dans les réseaux convolutifs (CNN) | Projet de recherche sous encadrement, laboratoire ICube | Python, PyTorch

- Conception et entraînement de trois architectures CNN comparables (baseline, bottleneck, bottleneck inversé) sur CIFAR-10, avec un protocole expérimental contrôlé.
- Analyse des représentations internes : hooks PyTorch, similarité cosinus, rang effectif (SVD) ; visualisations en Python ; mémoire en LaTeX.
- Conclusion : le bottleneck standard concentre la représentation (rang effectif 4,1/8 contre 7,7/8 pour le bottleneck inversé), un indice compatible avec la superposition sans en être la preuve ; félicitations et bonus du jury à la soutenance.

Prédiction de la gravité des accidents de la route en France | Projet de M1, équipe de 3 | Python, pandas, scikit-learn

- Construction et nettoyage du jeu de données : fusion de 6 sources ouvertes (BAAC 2024, INSEE), feature engineering (70 à 36 variables).
- En équipe : comparaison de 6 modèles (régression logistique, Random Forest, Gradient Boosting…) ; meilleur F1 (accidents graves) : 0,67.

GraviRoute : API de prédiction de la gravité des accidents | Projet personnel, suite du projet M1, en cours | Python, scikit-learn, FastAPI, Docker, MLflow, pytest

- En cours de développement : reprise du jeu de données du projet M1 pour construire un pipeline de production (prétraitement en Pipeline scikit-learn, régression logistique pondérée comparée à un Random Forest en validation croisée stratifiée à 5 folds, essais suivis dans MLflow).
- Service prévu : API FastAPI (POST /predict, entrées validées par Pydantic) conteneurisée avec Docker et docker-compose, testée avec pytest.

Analyse de la qualité de l'eau en France (2022) | Projet de M1, binôme | Python, scikit-learn, GeoPandas

- Préparation de 331 122 mesures pour 3 321 stations (lecture par blocs, jointures) ; clustering K-means et ACP, silhouette, carte des groupes de stations et jointure spatiale avec l'occupation du sol (CORINE Land Cover).

Analyse de données génomiques du cancer du sein (METABRIC) | Projet de M1 individuel | R, FactoMineR

- ACP, clustering K-means et tests du khi-deux sur 1 092 patientes et 100 gènes ; régression linéaire d'un indice de gravité.

Régression pénalisée et sélection de variables (Lasso) | TP noté de statistique, M1 | R, glmnet, caret

- Données simulées (300 observations, 20 variables en blocs corrélés) : Ridge, Lasso et Elastic-Net comparés sur 100 répétitions ; les deux vraies variables sont retenues 100 fois sur 100, le Lasso écarte le plus souvent les variables redondantes.
- Données publicitaires Criteo (clic = classe rare) : encodage one-hot creux, régression logistique Lasso (λ par validation croisée à 5 folds) et stability selection sur 30 sous-échantillons ; 2 variables stables retenues.

Base de données d'une application de suivi de tâches | Projet de L3 | Oracle, SQL

- Conception complète de la base de données, modélisation réalisée from scratch puis création du schéma sous Oracle.
- Écriture de requêtes SQL complexes pour interroger la base, avec présentation des résultats obtenus.

Ontologie du domaine musical | Projet de M1, individuel | Protégé, OWL, SPARQL, SQWRL

- Ontologie OWL (musiciens, groupes, chansons, récompenses) réutilisant FOAF, avec une classe intermédiaire pour les adhésions datées aux groupes ; 10 requêtes SPARQL et SQWRL écrites pour la valider, dont 9 réussies.

Extraction d'informations de fiches techniques par LLM | Projet de M1, équipe de 3 | Python, Mistral (API), pytest

- Ma part : chaîne d'extraction PDF → JSON de 20 champs avec Mistral Small 24B, prompts zero-shot et few-shot, évaluation et règles de validation contre les hallucinations ; F1 moyen 0,85 → 0,87 sur 4 fiches annotées à la main.
- Code en package Python de 6 modules, couvert par 24 tests pytest.

COMPÉTENCES

- **Langages :** Python, R, SQL, PL/SQL, C, C++, Java, C#.
- **Préparation de données :** pandas, NumPy, fusion de sources multiples avec jointures validées, nettoyage, feature engineering, encodage one-hot et creux, Parquet, GeoPandas et Shapely (jointures spatiales).
- **Machine learning :** scikit-learn (pipelines, sélection de variables), régression logistique, Random Forest, Gradient Boosting, AdaBoost, KNN, arbres de décision, K-means, ACP, XGBoost, LightGBM.
- **Évaluation et validation :** validation croisée stratifiée et groupée, GridSearchCV, détection et correction de fuite d'information, comparaison à une baseline, F1, rappel, AUC ; déséquilibre de classes (pondération, SMOTEENN, imbalanced-learn).
- **Statistiques (R) :** ACP (FactoMineR, factoextra), tests du khi-deux, régression linéaire, Ridge, Lasso et Elastic-Net (glmnet), stability selection, caret, tidyverse, R Markdown.
- **Deep learning :** PyTorch (hooks, torcheval), TensorFlow, Keras, CNN (bottleneck, convolutions depthwise), RNN, LSTM, embeddings GloVe, Edge AI (TFLite, ONNX).
- **LLM et NLP :** prompting zero-shot et few-shot, extraction structurée en JSON, Mistral via API, contrôle des hallucinations, augmentation par back-traduction (Hugging Face Transformers), RAG (LangChain).
- **Explicabilité :** SHAP, LIME, importance des variables, lecture des coefficients.
- **Séries temporelles :** ingénierie de caractéristiques temporelles, données satellites multi-spectrales (NDVI), modèles séquentiels.
- **Visualisation :** Matplotlib, Seaborn, cartographie (GeoPandas), Power BI, Tableau, Streamlit.
- **Bases de données et big data :** SQL, PL/SQL, Oracle, MySQL, PostgreSQL, MongoDB, Spark.
- **Web sémantique :** OWL, RDF (Turtle), SPARQL, SQWRL, Protégé, FOAF, rdflib.
- **Génie logiciel :** Git, packages Python, tests pytest et couverture, configuration YAML ; Unity, ASP.NET Core, SignalR ; flex, bison, Make ; travail en équipe de 10 (GitLab flow, revues de code).
- **Déploiement et MLOps :** Docker, FastAPI, MLflow (projet GraviRoute en cours).
- **Outils :** Jupyter, Google Colab, LaTeX.

SOFT SKILLS

- **Rigueur :** goût du travail bien fait et bien documenté.
- **Résilience et autonomie :** adaptation et apprentissage rapide de sujets nouveaux.
- **Présentation et communication :** compétence soulignée par mon encadrante de TER et par les félicitations du jury à la soutenance.

ENGAGEMENT ASSOCIATIF

- **Bénévolat :** maraudes et distributions aux étudiants, association Les Compagnons de l'Espoir ; SPA (rééducation et réintégration de chiens pour une vie de famille).
- **Vie étudiante :** membre de l'AIUS, association des étudiants en informatique ; aide à l'organisation d'événements, collecte de notes, fiches de révision et annales pour aider les promotions.

LANGUES ET CENTRES D'INTÉRÊT

Langues : français (C2), anglais (C2), arabe (langue maternelle) | Intérêts : l'IA dans son ensemble : nouveautés techniques, questions éthiques et épistémologiques.