Yasmina FARID

Stage de fin d'études Data Scientist (6 mois, dès 02/2027)

Strasbourg, France | yasmina.dsml@gmail.com | github.com/yasmina-dsml | linkedin.com/in/yasmina-farid-93231a196

PROFIL

Étudiante en M2 data science et IA (Université de Strasbourg), capable d'intervenir à chaque étape d'un pipeline d'IA : collecte de données et préparation complète, modèles de machine learning supervisés et non supervisés, deep learning et LLM (extraction, RAG), puis évaluation critique des résultats, reliés à leurs causes par l'explicabilité (LIME, SHAP). Recherche un stage de fin d'études de 6 mois dès 02/2027 sur des missions data à impact métier.

FORMATION

Master Informatique – CODIA : Connaissances, science des Données et Intelligence Artificielle | Université de Strasbourg | 09/2025 – 08/2027

- M2 (en cours) : données à large échelle, entreposage de données massives distribuées, Edge AI, mise en œuvre de l'IA.
- M1 : science des données et apprentissage, statistiques pour la science des données, apprentissage profond (deep learning), données complexes, programmation parallèle.

Licence Informatique | Université de Strasbourg | 09/2020 – 06/2024

- Programmation C et Java, bases de données (SQL, PL/SQL, Oracle), réseaux, génie logiciel, Git, développement web et d'applications.

PROJETS DATA SCIENCE

PrivRAG : assistant RAG sur documents privés, en mode 100 % local (en cours) | Projet de M2, équipe de 5, jusqu'à 01/2027 | Python, Qdrant, BM25, Ollama, GitLab

- Ma part (résumés et protocole d'évaluation) : protocole de benchmark inspiré de MLPerf Inference (latence p50/p95, RAM, CPU/GPU) et synthèse des comparatifs de l'équipe (extraction PDF, recherche BM25, vectorielle ou hybride, LLM local ou via API).
- Jeu d'évaluation de 25 questions annotées (simples, complexes, sans réponse), avec réponses attendues et passages sources vérifiés.

Prédiction de la gravité des accidents de la route en France | Projet de M1, équipe de 3 | Python, pandas, scikit-learn

- Construction et nettoyage du jeu de données : fusion de 6 sources ouvertes (BAAC 2024, INSEE), feature engineering (70 à 36 variables).
- En équipe : comparaison de 6 modèles (régression logistique, Random Forest, Gradient Boosting…) ; meilleur F1 (accidents graves) : 0,67.
- Prolongement personnel (GraviRoute) vers la mise en production : FastAPI, Docker, MLflow, pytest.
- Prolongement personnel (VigiRoute) vers un tableau de bord décisionnel : nettoyage, modèle en étoile et contrôles qualité en SQL (PostgreSQL), restitution sous Power BI.

Extraction d'informations de fiches techniques par LLM | Projet de M1, équipe de 3 | Python, Mistral (API), pytest

- Ma part : chaîne d'extraction PDF → JSON de 20 champs avec Mistral Small 24B, prompts zero-shot et few-shot, règles de validation contre les hallucinations ; F1 moyen de 0,87.
- Code en package Python de 6 modules, couvert par 24 tests pytest.

TER : superposition des caractéristiques dans les CNN | Projet de recherche encadré, laboratoire ICube | Python, PyTorch

- Conception et entraînement de trois architectures CNN comparables (baseline, bottleneck, bottleneck inversé) sur CIFAR-10, avec un protocole expérimental contrôlé.
- Analyse des représentations internes (hooks PyTorch, similarité cosinus, rang effectif par SVD) ; rang effectif 4,1/8 pour le bottleneck contre 7,7/8 pour sa version inversée ; félicitations et bonus du jury à la soutenance.

Classification de cultures par images satellites (Sentinel-2) | Projet de M1, équipe de 3, contribution individuelle | Python, scikit-learn, imbalanced-learn

- Ingénierie de caractéristiques sur séries temporelles mensuelles (statistiques par canal et par mois, NDVI) ; pipeline scikit-learn optimisé par GridSearchCV ; F1 macro de 0,48 sur 20 classes déséquilibrées (hasard : 0,05).

Classification de texte : régression logistique, RNN et LSTM | Projet de M1, équipe de 3 | Python, TensorFlow, Keras, Hugging Face

- Trois modèles développés par mes soins (LSTM avec embeddings GloVe), augmentation par back-traduction ; fuite d'information détectée au découpage des folds et corrigée par validation croisée groupée : le LSTM devient le meilleur modèle (accuracy 0,69 contre 0,64).

Autres projets : qualité de l'eau en France (K-means, ACP, GeoPandas) ; génomique du cancer du sein METABRIC (R) ; explicabilité LIME et SHAP d'un modèle d'attrition bancaire ; régression pénalisée Lasso (R, glmnet) ; base de données Oracle entièrement conçue (L3) ; ontologie OWL et SPARQL. Détails sur GitHub.

COMPÉTENCES

- **Langages :** Python, R, SQL, PL/SQL, C, C++, Java.
- **Données :** pandas, NumPy, PostgreSQL, Oracle, GeoPandas, Shapely, pdfplumber, pypdf, requests, PyYAML ; nettoyage, fusion de sources multiples, feature engineering.
- **Machine learning :** scikit-learn (pipelines, GridSearchCV), imbalanced-learn, XGBoost ; régression logistique, Random Forest, Gradient Boosting, K-means, ACP ; validation croisée, déséquilibre de classes ; SHAP, LIME.
- **Deep learning et LLM :** PyTorch (torchvision, torcheval), TensorFlow, Keras (CNN, RNN, LSTM), Hugging Face Transformers ; prompting, extraction structurée (API Mistral), évaluation de RAG.
- **Statistiques (R) :** tidyverse, FactoMineR, factoextra, glmnet, caret, R Markdown ; khi-deux, régression linéaire, Ridge, Lasso, Elastic-Net.
- **Outils :** Git, pytest, Jupyter, Matplotlib, Seaborn, LaTeX ; NetworkX, rdflib, OWL, SPARQL.
- **Notions :** C#, Spark, MongoDB, Docker, FastAPI, MLflow, Edge AI (TFLite, ONNX), Power BI, Tableau.

ENGAGEMENT ASSOCIATIF

- **Bénévolat :** maraudes et distributions aux étudiants (Les Compagnons de l'Espoir) ; SPA (rééducation de chiens en vue de leur adoption).
- **Vie étudiante :** membre de l'AIUS, association des étudiants en informatique ; organisation d'événements, fiches de révision et annales pour les promotions.

LANGUES, SOFT SKILLS ET INTÉRÊTS

Langues : français (C2), anglais (C2), arabe (langue maternelle) | Soft skills : rigueur, autonomie, communication (soulignée par l'encadrante du TER) | Intérêts : l'IA, ses nouveautés techniques et ses questions éthiques.