# Yasmina FARID

**Stage Data Scientist – stage de fin d'études de 6 mois à partir de 02/2027**

M2 Informatique, parcours CODIA (science des données et intelligence artificielle) – Université de Strasbourg
Strasbourg, France | yasmina.dsml@gmail.com | github.com/yasmina-dsml | linkedin.com/in/yasmina-farid-93231a196

## PROFIL

Étudiante en M2 data science et IA. Je construis des bases de données à partir de sources réelles multiples (jointures, nettoyage, feature engineering), puis j'en tire des analyses et des modèles de machine learning utiles à la décision, en Python et en R. Je cherche un stage en entreprise sur des données de santé, de finance ou d'économie.

## FORMATION

**Master Informatique, parcours CODIA – Connaissances, science des données et intelligence artificielle** | Université de Strasbourg | 09/2025 – 08/2027

- M2 (en cours) : données à large échelle (Spark), entreposage de données massives distribuées, Edge AI, mise en œuvre de l'IA.
- M1 (mention assez bien) : science des données et apprentissage, statistiques pour la science des données, apprentissage profond (deep learning), données complexes, programmation parallèle.

**Licence Informatique** | Université de Strasbourg | 09/2020 – 06/2024

- Programmation C et Java, bases de données (SQL, PL/SQL, Oracle), réseaux, génie logiciel, Git.

## PROJETS DATA SCIENCE

**Modèles séquentiels : régression logistique, RNN et LSTM** | Projet de M1, équipe de 3, contribution individuelle | Python, Keras, Hugging Face

- Comparaison de trois modèles de classification de texte (régression logistique, RNN, LSTM avec embeddings GloVe) ; back-traduction (215 → 274 phrases) : +7 points en test pour le RNN, +4 pour le LSTM.
- Fuite d'information localisée (paraphrases séparées de leur phrase source entre folds) et corrigée par validation croisée groupée : la régression logistique passe de 0,73 à 0,64 et le LSTM devient le meilleur modèle (0,69).

**Classification de cultures agricoles à partir de séries temporelles d'images satellites (Sentinel-2)** | Projet de M1, équipe de 3, contribution individuelle | Python, scikit-learn, imbalanced-learn

- Ingénierie de caractéristiques sur séries temporelles mensuelles : statistiques par canal et par mois, indice de végétation NDVI pour suivre le cycle de croissance.
- Pipeline scikit-learn (standardisation, sélection de variables, régression logistique multiclasse, 20 classes déséquilibrées) optimisé par GridSearchCV ; F1 macro de 0,48 en test (hasard : 0,05), 0,61 en validation croisée.

**TER : superposition des caractéristiques dans les réseaux de neurones convolutifs (CNN)** | Projet de recherche individuel, laboratoire ICube, félicitations du jury | Python, PyTorch

- Conception et entraînement de trois architectures CNN comparables (baseline, bottleneck, bottleneck inversé) sur CIFAR-10, avec un protocole expérimental contrôlé.
- Analyse des représentations internes (hooks PyTorch, similarité cosinus, rang effectif par SVD) : rang effectif de 4,1/8 pour le bottleneck contre 7,7/8 pour le bottleneck inversé ; mémoire en LaTeX.

**Prédiction de la gravité des accidents de la route en France** | Projet de M1, équipe de 3 | Python, pandas, scikit-learn

- Ma part : construction et nettoyage du jeu de données, avec la fusion de 6 sources ouvertes (BAAC 2024, INSEE), feature engineering (70 à 36 variables).
- En équipe : comparaison de 6 modèles (régression logistique, Random Forest…) ; F1 grave de 0,67 (baseline : 0,53).

**Analyse de la qualité de l'eau en France (2022)** | Projet de M1, binôme | Python, scikit-learn, GeoPandas

- Préparation de 331 122 mesures pour 3 321 stations (lecture par blocs, jointures) ; K-means et ACP, silhouette, jointure spatiale.

**Analyse de données génomiques du cancer du sein (METABRIC)** | Projet de M1 individuel | R, FactoMineR

- ACP, clustering K-means et tests du khi-deux sur 1 092 patientes et 100 gènes ; régression linéaire d'un indice de gravité.

## COMPÉTENCES

- **Langages :** Python, R, SQL, PL/SQL, C, Java.
- **Machine learning :** scikit-learn, pipelines, GridSearchCV, régression logistique, Random Forest, Gradient Boosting, K-means, ACP, validation croisée, gestion du déséquilibre de classes.
- **Deep learning :** PyTorch, TensorFlow, Keras, CNN, RNN, LSTM, Hugging Face Transformers, embeddings.
- **Séries temporelles :** ingénierie de caractéristiques temporelles, données satellites multi-spectrales, modèles séquentiels.
- **Statistiques et visualisation :** tests du khi-deux, régression linéaire, Matplotlib, Seaborn.
- **Données et outils :** pandas, NumPy, Spark, GeoPandas, Parquet, Git, Jupyter, Google Colab, LaTeX, R Markdown.

## ENGAGEMENT ASSOCIATIF

- **Bénévolat :** maraudes et distributions aux étudiants, association Les Compagnons de l'Espoir ; SPA.
- **Vie étudiante :** membre de l'AIUS, association des étudiants en informatique.

## LANGUES ET CENTRES D'INTÉRÊT

Langues : français, anglais et arabe courants | Centres d'intérêt : éthique et épistémologie de l'IA, voyages en camping-car.