Yasmina FARID

Stage de fin d'études en Data Science / Machine Learning (6 mois, dès 02/2027)

Master Informatique – CODIA : Connaissances, science des données et intelligence artificielle | **Université de Strasbourg**
Lieu : France entière | yasmina.dsml@gmail.com | github.com/yasmina-dsml | linkedin.com/in/yasmina-farid-93231a196

PROFIL

Étudiante en M2 data science et IA. De la collecte et la préparation des données à l'évaluation critique des modèles : ML supervisé et non supervisé, deep learning, LLM (extraction, RAG).

FORMATION

Master Informatique – CODIA : Connaissances, science des données et intelligence artificielle | Université de Strasbourg | 09/2025 – 08/2027

- M2 (en cours) : données à large échelle, entreposage de données massives distribuées et Business Intelligence, mise en œuvre de l'Edge AI.
- M1 : science des données et apprentissage, statistiques pour la science des données, apprentissage profond (deep learning), données complexes, programmation parallèle.

Licence Informatique | Université de Strasbourg | Diplôme obtenu en 2024

- Programmation C et Java, bases de données (SQL, PL/SQL, Oracle), réseaux, génie logiciel, Git, développement web et d'applications (Unity, C#, .NET)

PROJETS DATA SCIENCE

PrivRAG : assistant RAG sur documents privés étudiant, en mode 100 % local | Projet de M2 en cours (jusqu'à 01/2027), équipe de 5 | Python, Qdrant, BM25, Ollama, GitLab

- Gestion des résumés et du protocole d'évaluation de bout en bout : protocole de benchmark inspiré de MLPerf Inference (latence p50/p95, RAM, CPU/GPU) et synthèse des comparatifs de l'équipe (extraction PDF, recherche BM25, vectorielle ou hybride, LLM local ou via API).
- Création et méthodes d'enrichissement du jeu d'évaluation en questions annotées (simples, complexes, sans réponse), avec réponses attendues et passages sources vérifiés en structure JSON.

Prédiction de la gravité des accidents de la route en France | Projet de M1, équipe de 3 | Python, pandas, scikit-learn

- Construction et nettoyage du jeu de données : fusion de 6 sources ouvertes (BAAC 2024, INSEE), feature engineering (70 à 36 variables).
- En équipe : comparaison de 6 modèles (régression logistique, Random Forest, Gradient Boosting…) ; meilleur F1 (accidents graves) : 0,67.
- Prolongements en projets personnels en cours : GraviRoute (mise en production : FastAPI, Docker, MLflow) et VigiRoute (tableau de bord Power BI, modèle en étoile PostgreSQL).

Extraction d'informations de fiches techniques par LLM | Projet de M1, équipe de 3 | Python, Mistral (API), pytest

- Chaîne d'extraction PDF → JSON de 20 champs avec Mistral Small 24B, prompts zero-shot et few-shot, règles de validation contre les hallucinations ; F1 moyen de 0,87.
- Code en package Python de 6 modules, couvert par 24 tests pytest.

Classification de cultures par images satellites (Sentinel-2) | Projet de M1, équipe de 3, contribution individuelle | Python, scikit-learn, imbalanced-learn

- Ingénierie de caractéristiques sur séries temporelles mensuelles (statistiques par canal et par mois, NDVI) ; pipeline scikit-learn optimisé par GridSearchCV ; F1 macro de 0,48 sur 20 classes déséquilibrées (hasard : 0,05).

Analyse de la qualité de l'eau en France (2022) | Projet de M1, binôme | Python, scikit-learn, GeoPandas

- Préparation de 331 122 mesures pour 3 321 stations (lecture par blocs, jointures) ; clustering K-means et ACP, score de silhouette, croisement spatial, visualisation des résultats sur carte.

TER : superposition des caractéristiques dans les CNN | Projet de recherche encadré, laboratoire ICube | Python, PyTorch

- Conception et entraînement de trois architectures CNN comparables (baseline, bottleneck, bottleneck inversé) sur CIFAR-10, avec un protocole expérimental contrôlé.
- Analyse des représentations internes (hooks PyTorch, similarité cosinus, rang effectif par SVD) ; rang effectif 4,1/8 pour le bottleneck contre 7,7/8 pour sa version inversée ; félicitations et bonus du jury à la soutenance.

Autres projets : classification de texte RNN et LSTM (sentiment analysis) avec correction d'une fuite d'information relevée ; génomique du cancer du sein METABRIC (R) ; explicabilité LIME et SHAP d'un modèle d'attrition bancaire ; régression pénalisée Lasso (R, glmnet) ; base de données Oracle entièrement conçue (L3) pour application de gestion des tâches ; ontologie OWL et requêtes SPARQL. (Détails sur GitHub)

COMPÉTENCES

- **Langages :** C, C++, Java, Python, R, SQL (PostgreSQL, Oracle, PL/SQL).
- **Données :** pandas, NumPy ; nettoyage, fusion de sources multiples, analyse exploratoire, feature engineering.
- **Machine learning :** apprentissage supervisé (classification, régression) et non supervisé (clustering, ACP) ; évaluation et validation des modèles (validation croisée, métriques, déséquilibre de classes) ; optimisation des hyperparamètres ; explicabilité (SHAP, LIME) ; scikit-learn, XGBoost.
- **Deep learning et LLM :** PyTorch, TensorFlow, Keras, Hugging Face ; CNN, RNN, LSTM ; prompting, extraction structurée, évaluation de RAG.
- **Statistiques (R) :** tidyverse, FactoMineR, glmnet ; ACP, khi-deux, régression linéaire, Ridge, Lasso.
- **Outils :** Git, Docker, FastAPI, MLflow, pytest, Jupyter, Matplotlib, Seaborn, LaTeX.
- **Notions :** C#, Spark, MongoDB, Power BI, Tableau, Edge AI (TFLite, ONNX), OWL, SPARQL, pipeline RAG.

ENGAGEMENT ASSOCIATIF

- **Bénévolat :** maraudes et distributions aux étudiants (Les Compagnons de l'Espoir) ; SPA (rééducation de chiens en vue de leur adoption).
- **Vie étudiante :** membre de l'AIUS, association des étudiants en informatique ; organisation d'événements, fiches de révision et annales pour les promotions.

LANGUES, SOFT SKILLS ET INTÉRÊTS

Langues : français (C2), anglais (C2), arabe (maternelle) | Soft skills : rigueur et goût du travail bien fait, autonomie, facilité à communiquer en équipe | Intérêts : l'IA, ses nouveautés techniques et ses divers impacts.