Université de Strasbourg

Master 1 Science des Données et Calcul Scientifique

Extraction d'Informations de Datasheets de Batteries par LLM

Structuration en Knowledge Graph et Détection d'Hallucinations

Auteurs : Yasmina Farid
Olivia Amele Adamah
Fatima Ould Hammouda

Formation : M1 SDSC, Université de Strasbourg

Modèle LLM : Mistral Small 3.2 24B (mai.ia.unistra.fr)

Date : Mai 2026

Table des matières

1 Introduction **2**

2 Données utilisées **2**
2.1 Les quatre datasheets . . . 2
2.2 Vérités terrain . . . 2

3 Level 1 — Extraction LLM **2**
3.1 Pipeline d'extraction . . . 2
3.2 Champs extraits . . . 3
3.3 Stratégies de prompting . . . 3
3.4 Métriques d'évaluation . . . 4
3.5 Résultats d'évaluation . . . 4

4 Level 2 — Knowledge Graph **4**
4.1 Ontologie OWL . . . 4
4.2 Conversion JSON vers triples RDF . . . 5
4.3 Requêtes SPARQL . . . 6
4.4 Graphe de connaissances peuplé . . . 6

5 Level 3 — Détection d'hallucinations **7**
5.1 3 niveaux de validation . . . 7

6 Conclusion **7**

1 Introduction

Les datasheets de batteries contiennent des spécifications techniques critiques (tension, capacité, température, résistance interne, etc.) mais sont souvent fournies au format PDF non structuré. Ce projet propose un pipeline intelligent combinant LLM et graphe de connaissances pour extraire, structurer et valider ces informations automatiquement.

Trois niveaux ont été implémentés :

1. **Level 1** — Extraction LLM avec comparaison zero-shot / few-shot et métriques P/R/F1
2. **Level 2** — Knowledge Graph RDF/OWL avec requêtes SPARQL
3. **Level 3** — Détection d'hallucinations par validation multi-niveaux

2 Données utilisées

2.1 Les quatre datasheets

TABLE 1 – Datasheets de batteries utilisées dans le projet

Modèle	Chimie	Tension	Capacité	Fabricant
LIR2450	Li-ion	3.6 V	120 mAh	EEMB Co., Ltd.
16340	Li-ion	3.2 V	500 mAh	DNK Power o., Ltd.
PL-9059156	Polymer Li-ion	3.7 V	11 500 mAh	AA Portable Power
FFH3DS (CATL)	LiFePO4	3.2 V	86 Ah	CATL

Ces quatre batteries couvrent différentes chimies, fabricants et gammes de capacité (120 mAh à 86 Ah), afin de tester la robustesse du système face à la diversité des documents.

2.2 Vérités terrain

Pour chaque batterie, une vérité terrain a été constituée par annotation manuelle du PDF. Chaque fichier JSON contient 20 champs structurés avec valeurs et unités séparées (ex. `charge_current: 24`, `charge_current_unit: "mA"`).

3 Level 1 — Extraction LLM

3.1 Pipeline d'extraction

Le pipeline suit quatre étapes :

1. **Extraction PDF** — `pypdf` qui est plus simple mais plus rapide puis `pdfplumber` qui est plus avancée et adapté au tableaux.
2. **Prompt LLM** — Le texte est envoyé au serveur Mistral de l'Unistra avec une liste de 20 champs à extraire et des contraintes de format, en plus de quelques directives tel que pour la conversion. .
3. **Parsing JSON** — Mistral peut entourer le JSON de texte explicatif des fois donc le code extrait automatiquement le JSON par recherche des accolades.
4. **Validation** — Les valeurs extraites sont validées et un `confidence_score` est calculé (voir Level 3).

3.2 Champs extraits

TABLE 2 – Les 20 champs extraits

Champ	Description	Unité
model	Référence batterie	—
manufacturer	Fabricant	—
chemistry	Li-ion, LiFePO4, Li-Po, NiMH	—
voltage / voltage_unit	Tension nominale	V
capacity / capacity_unit	Capacité	mAh ou Ah
charge_current / unit	Courant de charge	A ou mA
discharge_current / unit	Courant de décharge	A ou mA
internal_resistance / unit	Résistance interne	mΩ
temperature_range	Plage de fonctionnement	°C
dimensions	Dimensions physiques	mm
weight / weight_unit	Poids	g ou kg
cycle_life	Nombre de cycles	—
charge_cutoff_voltage	Tension fin de charge	V
discharge_cutoff_voltage	Tension fin de décharge	V

3.3 Stratégies de prompting

Zero-shot. Le texte du PDF est envoyé directement avec la liste des 20 champs, sans exemple, le modèle doit inférer le format attendu tout seul.

Few-shot. Un exemple complet avec un datasheet fictive et les réponses en JSON attendues est fourni avant la question. L'exemple guide notamment la conversion des C-rates en Ampères pour les résistances (0.2C × 120 mAh = 24 mA) et la séparation valeur/unité.

3.4 Métriques d'évaluation

Les métriques Précision, Recall et F1 sont calculées champ par champ puis ils sont comparés avec une tolérance de 5%.On s'est surtout basé sur le score F1 pour comparer les deux stratégies.

3.5 Résultats d'évaluation

TABLE 3 – Résultats zero-shot vs few-shot sur les 4 PDFs de batteries

Batterie	**Zero-shot**			**Few-shot**			**ΔF1**
	P	R	F1	P	R	F1	
16340	0.8824	0.7895	0.8333	0.8824	0.7895	**0.8333**	+0.0000
PL-9059156	0.6316	0.6667	0.6486	0.6842	0.7222	**0.7027**	+0.0541
CATL	0.9500	0.9500	0.9500	0.9500	0.9500	**0.9500**	+0.0000
LIR2450	0.9091	1.0000	0.9524	1.0000	1.0000	**1.0000**	+0.0476
Moyenne	0.8433	0.8516	0.8461	0.8791	0.8654	**0.8715**	**+0.0254**

Globalement, le prompting few-shot améliore le score F1 moyen, qui passe de 0.8461 à 0.8715, soit un gain de +0.0254. Cette amélioration reste modérée, car la stratégie zero-shot obtient déjà de bons résultats sur la plupart des datasheets grâce au prompt rigoureux. Cependant, le few-shot améliore quand même la précision et le rappel sur certains documents, en particulier PL-9059156 et LIR2450.

4 Level 2 — Knowledge Graph

4.1 Ontologie OWL

TABLE 4 – Composants de l'ontologie OWL

Composant	**Contenu**
Classes	Battery, LithiumIonBattery, LiFePO4Battery, LiPolymerBattery, NiMHBattery, Specification, Unit
DatatypeProperty	20 propriétés : voltage, capacity, manufacturer, chemistry, etc.
ObjectProperty	similarVoltage, sameChemistry, similarCapacityRange
Individus unités	V, mAh, Ah, A, mA, mΩ, Ω, g, kg, °C
Contraintes	voltage : 0.5–12 V ; résistance : 0.1–1000 mΩ ; cycles : 1–10 000

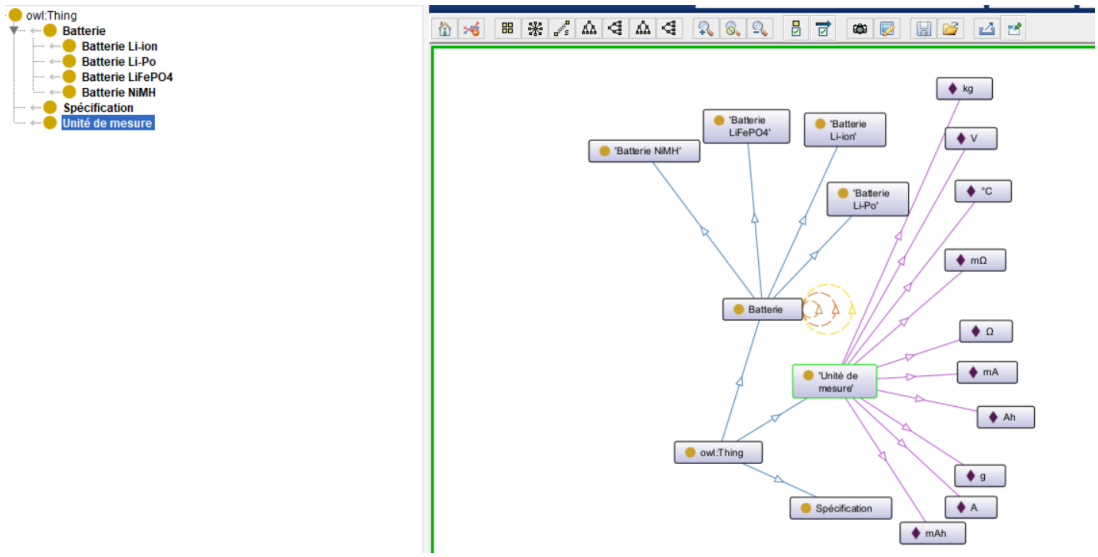


FIGURE 1 – Vue OntoGraf (Protégé) — hiérarchie de classes et instances d'unités

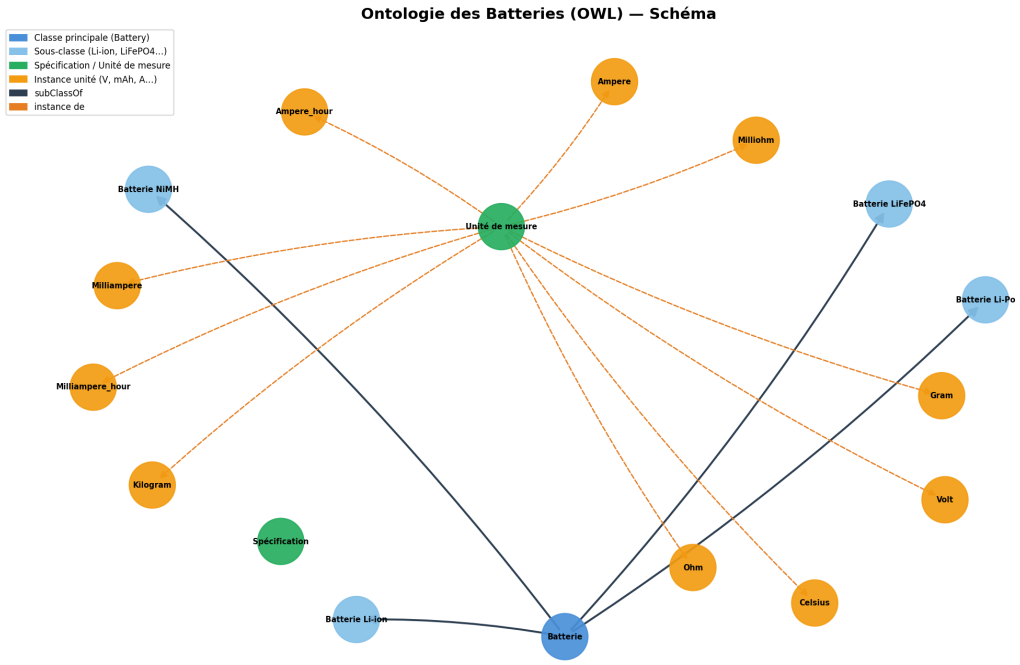


FIGURE 2 – Visualisation Python de l'ontologie OWL — classes (bleu), sous-classes (bleu clair), unités (orange)

4.2 Conversion JSON vers triples RDF

Les fichiers JSON produits par l'étape d'extraction sont ensuite rechargés pour d'alimenter le graphe de connaissances. Chaque batterie est transmise à une méthode qui convertit les champs extraits en triples RDF selon le schéma de l'ontologie. Les propriétés JSON comme `voltage`, `capacity` ou `manufacturer` sont ainsi associées à des propriétés RDF correspondantes. Le graphe final est exporté au format Turtle et peut être interrogé avec SPARQL via `rdflib`.

4.3 Requêtes SPARQL

Quatre requêtes ont été exécutées :

TABLE 5 – Requêtes SPARQL et leurs résultats

Requête	Critère	Résultats
1	Toutes batteries + tension	16340 (3.2V), FFH3DS (3.2V), LIR2450 (3.6V), 9059156 (3.7V)
2	Batteries par chimie	LIR2450 (Li-ion), FFH3DS (LiFePO4), 9059156 (Polymer Li-ion)
3	Tension > 3.5 V	LIR2450 (3.6V), PL-9059156 (3.7V)
4	Cycles > 500	FFH3DS CATL (3500 cycles)

4.4 Graphe de connaissances peuplé

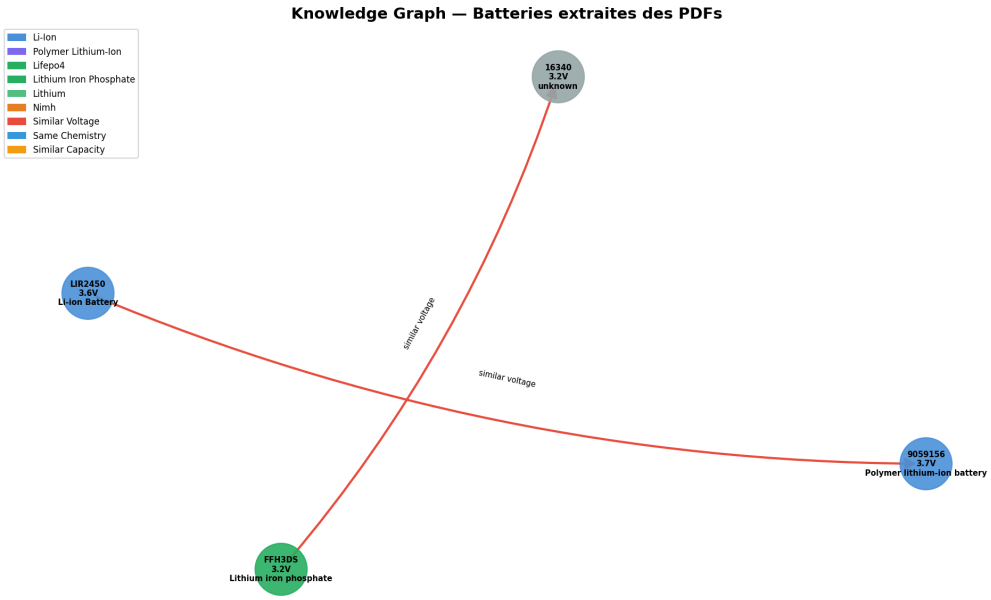


FIGURE 3 – Knowledge Graph peuplé — 4 batteries extraites des PDFs avec leurs relations sémantiques. Bleu = Li-ion, vert = LiFePO4, violet = Polymer Li-ion. Flèches rouges = similarVoltage.

Les relations automatiques générées :

— **LIR2450 – PL-9059156** : `similarVoltage` (3.6V vs 3.7V, écart 0.1V $\leq$ 0.2V)

— **FFH3DS – 16340** : `similarVoltage` (3.2V vs 3.2V)

5 Level 3 — Détection d'hallucinations

5.1 3 niveaux de validation

La confiance de base est de 1, puis la validation s'applique automatiquement à chaque extraction et pénalise le `confidence_score` proportionnellement aux violations :

CRITIQUE $\times 0.3$ MAJEUR $\times 0.7$ MINEUR $\times 0.9$

Niveau 1 — DataValidator : Règles physiques fixes :

TABLE 6 – Règles de validation physique

Règle	**Condition**	**Sévérité**
Plage voltage	$1.0 \text{ V} \leq V \leq 5.0 \text{ V}$	CRITIQUE
Plage capacité	$10 \leq C \leq 100000$ mAh	CRITIQUE
Plage température	$T_{min} \geq -40C$ et $T_{max} \leq 85C$	MAJEUR
Cohérence chimie/voltage	Li-ion : 3.6–4.2 V ; LiFePO4 : 3.0–3.6 V	MAJEUR
Voltage entier suspect	$V \in \{1, 2, 3, 4, 5, 6\}$	MINEUR
Capacité multiple de 1000	$C > 1000$ et $C \bmod 1000 = 0$	MINEUR
Puissance irréaliste	$V \times C_{Ah} > 1000$ Wh	MAJEUR

Niveau 2 — Validation OWL : Les contraintes formelles de `battery_ontology.owl` sont vérifiées : bornes min/max des propriétés, cohérence chimie/voltage issue des règles OWL.

Niveau 3 — Validation basée sur le graphe : Une validation dynamique : elle interroge par requêtes SPARQL les batteries déjà dans le graphe pour calculer la plage de voltage observée par chimie. Si une nouvelle batterie déclare une chimie "Li-ion" avec 10V alors que les Li-ion du graphe sont à 3.2–3.7V, une violation est levée.

6 Conclusion

- **Level 1** : le few-shot obtient de meilleurs résultats que le zero-shot, avec un F1 moyen de 0.84.
- **Level 2** : les données extraites sont transformées en graphe de connaissances grâce à une ontologie OWL et peuvent être interrogées avec SPARQL.
- **Level 3** : le système de validation permet de détecter des valeurs incohérentes ou hallucinées.