« Superposition et interférence des caractéristiques extraites dans un réseau de neurones convolutif »

Anne Jeannin-Girardon – anne.jeannin@unistra.fr

Contexte

L'architecture des blocs de convolution influence la géométrie de l'espace latent utilisé par un modèle pour représenter les caractéristiques des données utilisées pour l'entraîner. Les réseaux de neurones artificiels peuvent représenter de multiples caractéristiques sur une unique dimension de l'espace latent : si cette stratégie de superposition se montre efficace pour que le modèle résultant soit performant, il est aussi possible que l'apprentissage soit rendu plus difficile à cause de ce phénomène, on parle alors d'interférence des caractéristiques entre elles. Plus largement, la superposition complexifie également la possibilité d'interpréter les représentations apprises par un modèle.

L'objectif de ce travail est de réaliser une étude empirique des phénomènes de superposition et d'interférence (Elhage et coll., 2022 ; Hollard et coll., 2025) pour différentes architectures de blocs de convolution : standard (*baseline*), *depthwise separable*, goulet d'étranglement et goulet d'étranglement inversé, *ConvNeXt*, goulet asymétrique, goulet *sandglass*, etc.

Travail demandé

Une première phase de travail consistera à réaliser un état des lieux des grandes architectures de blocs de convolution (incluant les blocs mentionnés ci-dessus, ainsi que d'autres blocs pertinents pour l'étude (Younesi et coll., 2024 ; Liu et coll., 2024)). Ce travail sera complété par une étude approfondie du travail mené par Elhage et coll. (2022) sur la superposition ou l'interférence des caractéristiques sur les dimensions de l'espace latent.

Le volet expérimental de ce TER consistera à établir et mettre en œuvre un protocole permettant d'évaluer l'indépendance des caractéristiques apprises par différents types de blocs à travers différentes mesures (e.g. maintenance des performances sous SoLU, similarité cosinus, rang effectif, etc.), afin d'examiner dans quelle mesure certains blocs semblent intrinsèquement plus prônes à apprendre des caractéristiques indépendantes, ou encore s'il est avantageux que les caractéristiques bas (resp. haut) niveau soient plus indépendantes qu'à haut (resp. bas) niveau.

Bibliographie indicative (non exhaustive)

Elhage, N., Hume, T., Olsson, C., Schiefer, N., Henighan, T., Kravec, S., Hatfield-Dodds, Z., Lasenby, R., Drain, D., Chen, C., Grosse, R., McCandlish, S., Kaplan, J., Amodei, D., Wattenberg, M., & Olah, C. (2022). Toy Models of Superposition. arXiv. https://doi.org/10.48550/arXiv.2209.10652

Hollard, L., Mohimont, L., Gaveau, N., & Steffenel, L.-A. (2025). Exploring Superposition and Interference in State-of-the-Art Low-Parameter Vision Models. arXiv. https://doi.org/10.48550/arXiv.2507.15798

Liu, Y., Xue, J., Li, D., Zhang, W., Chiew, T. K., & Xu, Z. (2024). Image recognition based on lightweight convolutional neural network : Recent advances. Image and Vision Computing, 146, 105037. https://doi.org/10.1016/j.imavis.2024.105037

Purvine, E., Brown, D., Jefferson, B., Joslyn, C., Praggastis, B., Rathore, A., Shapiro, M., Wang, B., & Zhou, Y. (2023). Experimental Observations of the Topology of Convolutional Neural Network Activations. Proceedings of the AAAI Conference on Artificial Intelligence, 37(8), 9470-9479. https://doi.org/10.1609/aaai.v37i8.26134

Younesi, A., Ansari, M., Fazli, M., Ejlali, A., Shafique, M., & Henkel, J. (2024). A Comprehensive Survey of Convolutions in Deep Learning : Applications, Challenges, and Future Trends. IEEE Access, 12, 41180-41218. https://doi.org/10.1109/ACCESS.2024.3376441